hw text classification

June 5, 2023

1 Домашнее задание. Нейросетевая классификация текстов

В этом домашнем задании вам предстоит самостоятельно решить задачу классификации текстов на основе семинарского кода. Мы будем использовать датасет ag_news. Это датасет для классификации новостей на 4 темы: "World", "Sports", "Business", "Sci/Tech".

Установим модуль datasets, чтобы нам проще было работать с данными.

```
[]: | !pip install datasets torchinfo -q
```

```
30.2 MB/s eta 0:00:00
 16.0 MB/s eta 0:00:00
 25.1 MB/s eta 0:00:00
 12.4 MB/s eta 0:00:00
 ======== 1.0/1.0 MB
76.3 MB/s eta 0:00:00
 24.3 MB/s eta 0:00:00
 12.8 MB/s eta 0:00:00
 21.5 MB/s eta 0:00:00
 16.0 MB/s eta 0:00:00
```

2 Imports and settings

```
[]: import collections
  import os
  import random
  import string
  import time
  import typing
```

```
import matplotlib
     import matplotlib.pyplot as plt
     import numpy as np
     import seaborn as sns
     import tqdm.notebook as tqdm
     %matplotlib inline
     import datasets
     import nltk
     import nltk.tokenize
     import sklearn
     import sklearn.model_selection
     import torch
     import torch.nn
     import torch.functional
     import torch.utils.data as data_utils
     import torchinfo
[]: sns.set(style="darkgrid", font_scale=1.2)
     plt.rcParams["figure.figsize"] = (20, 20)
[]: nltk.download("punkt")
    [nltk_data] Downloading package punkt to /root/nltk_data...
    [nltk_data]
                  Unzipping tokenizers/punkt.zip.
[]: True
```

3 Setting random seeds for reproducibility

```
[]: # Check CUDA version
!nvcc --version

nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2022 NVIDIA Corporation
Built on Wed_Sep_21_10:33:58_PDT_2022
Cuda compilation tools, release 11.8, V11.8.89
Build cuda_11.8.r11.8/compiler.31833905_0

[]: RANDOM_STATE = 42
def fix_seed(state):
    random.seed(state)
    os.environ["PYTHONHASHSEED"] = str(state)
    np.random.seed(state)
    torch.manual_seed(state)
```

[]: <torch. C.Generator at 0x7fe9398f7ef0>

4 Determining available device

```
[]: DEVICE = "cuda" if torch.cuda.is_available() else "cpu"
DEVICE
```

[]: 'cuda'

5 Setting global variables

```
[]: BATCH_SIZE = 512
COUNTER_THRESHOLD = 25
```

6 Preprocessing

Для вашего удобства, мы привели код обработки датасета в ноутбуке. Ваша задача — обучить модель, которая получит максимальное возможное качество на тестовой части.

```
[]: dataset = datasets.load_dataset("ag_news")
                                                | 0.00/4.06k [00:00<?, ?B/s]
    Downloading builder script:
                                  0%|
                                          | 0.00/2.65k [00:00<?, ?B/s]
    Downloading metadata:
                            0%|
    Downloading readme:
                          0%1
                                        | 0.00/7.95k [00:00<?, ?B/s]
    Downloading and preparing dataset ag_news/default to /root/.cache/huggingface/da
    tasets/ag_news/default/0.0.0/bc2bcb40336ace1a0374767fc29bb0296cdaf8a6da729843623
    9c54d79180548...
    Downloading data:
                        0%1
                                     | 0.00/11.0M [00:00<?, ?B/s]
```

```
Downloading data: 0% | | 0.00/751k [00:00<?, ?B/s]

Generating train split: 0% | | 0/120000 [00:00<?, ? examples/s]

Generating test split: 0% | | 0/7600 [00:00<?, ? examples/s]
```

Dataset ag_news downloaded and prepared to /root/.cache/huggingface/datasets/ag_news/default/0.0.0/bc2bcb40336ace1a0374767fc29bb0296cdaf8a6da7298436239c54d79180 548. Subsequent calls will reuse this data.

```
0% | 0/2 [00:00<?, ?it/s]
```

Как и в семинаре, выполним следующие шаги: * Составим словарь * Создадим класс Word-Dataset * Выделим обучающую и тестовую часть, создадим DataLoader-ы.

```
[]: def create_vocab(dataset, threshold=COUNTER_THRESHOLD):
        words = collections.Counter()
        for example in tqdm.tqdm(dataset["train"]["text"], desc="Preprocessing", u
     # Lowercase and remove punctuation
            processed_text = example.lower().translate(
                str.maketrans("", "", string.punctuation))
            for word in nltk.tokenize.word_tokenize(processed_text):
                words[word] += 1
        vocab = collections.OrderedDict.fromkeys(["<unk>", "<bos>", "<eos>", "
     →"<pad>"]) # ordered replacement for set
        for char, cnt in tqdm.tqdm(words.items(), desc="Selecting frequent tokens", u
     →unit="tokens", unit_scale=False):
            if cnt > threshold:
                vocab[char] = None
        word2ind = {char: i for i, char in enumerate(vocab.keys())}
        ind2word = {i: char for char, i in word2ind.items()}
        return vocab, word2ind, ind2word
```

Vocabulary size: 11842

```
[]: class WordDataset(data_utils.Dataset):
         def __init__(self, sentences):
             super().__init__()
             self.data = sentences
             self.unk id = word2ind["<unk>"]
             self.bos_id = word2ind["<bos>"]
             self.eos_id = word2ind["<eos>"]
             self.pad_id = word2ind["<pad>"]
         def __getitem__(self, idx: int) -> typing.List[int]:
             processed_text = self.data[idx]["text"].lower().translate(
                 str.maketrans("", "", string.punctuation))
             tokenized_sentence = [self.bos_id]
             tokenized_sentence += [
                 word2ind.get(word, self.unk_id) for word in nltk.tokenize.
      →word_tokenize(processed_text)
             tokenized_sentence += [self.eos_id]
             train_sample = {
                 "text": tokenized_sentence,
                 "label": self.data[idx]["label"]
             }
             return train_sample
         def __len__(self) -> int:
             return len(self.data)
     def collate_fn_with_padding(
         input_batch: typing.List[typing.List[int]], pad_id=word2ind["<pad>"],_
      →max_len=256) -> torch.Tensor:
         seq_lens = [len(x["text"]) for x in input_batch]
         max_seq_len = min(max(seq_lens), max_len)
         new batch = []
         for sequence in input_batch:
             sequence["text"] = sequence["text"][:max_seq_len]
             for _ in range(max_seq_len - len(sequence["text"])):
                 sequence["text"].append(pad_id)
             new_batch.append(sequence["text"])
         sequences = torch.LongTensor(new_batch)
         labels = torch.LongTensor([x["label"] for x in input_batch])
```

```
new_batch = {
    "input_ids": sequences,
    "label": labels
}
return new_batch
```

```
[]: # The following function will use a fixed seed for DataLoader worker init def seed_worker(worker_id):
    worker_seed = torch.initial_seed() % 2**32
    fix_seed(worker_seed)
```

```
[]: train_dataset = WordDataset(dataset["test"]))
idx = torch.randperm(len(dataset["test"]))[:5000]
eval_dataset = WordDataset(dataset["test"].select(idx))

train_dataloader = data_utils.DataLoader(
    train_dataset, shuffle=True, collate_fn=collate_fn_with_padding,
    batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(),
    worker_init_fn=seed_worker, generator=TORCH_RAND_GEN, pin_memory=True)

eval_dataloader = data_utils.DataLoader(
    eval_dataset, shuffle=False, collate_fn=collate_fn_with_padding,
    batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(),
    worker_init_fn=seed_worker, generator=TORCH_RAND_GEN, pin_memory=True)
```

7 Постановка задачи

Ваша задача — получить максимальное возможное accuracy на eval_dataloader. Ниже приведена функция, которую вам необходимо запустить для обученной модели, чтобы вычислить качество её работы.

```
[]: def evaluate(model, eval_dataloader) -> float:
    """
    Calculate accuracy on validation dataloader.
    """

    predictions = []
    target = []
    with torch.no_grad():
        for batch in eval_dataloader:
            logits = model(batch["input_ids"].to(DEVICE))
            predictions.append(logits.argmax(dim=1))
            target.append(batch["label"])

    predictions = torch.cat(predictions)
    target = torch.cat(target).to(DEVICE)
```

```
accuracy = (predictions == target).float().mean().item()
return accuracy
```

8 Ход работы

Оценка за домашнее задание складывается из четырех частей: ## Запуск базовой модели с семинара на новом датасете (1 балл) На семинаре мы создали модель, которая дает на нашей задаче довольно высокое качество. Ваша цель — обучить ее и вычислить score, который затем можно будет использовать в качестве бейзлайна.

В модели появится одно важное изменение: количество классов теперь равно не 2, а 4. Обратите на это внимание и найдите, что в коде создания модели нужно модифицировать, чтобы учесть это различие.

8.1 Проведение экспериментов по улучшению модели (2 балла за каждый эксперимент)

Чтобы улучшить качество базовой модели, можно попробовать различные идеи экспериментов. Каждый выполненный эксперимент будет оцениваться в 2 балла. Для получения полного балла за этот пункт вам необходимо выполнить по крайней мере 2 эксперимента. Не расстраивайтесь, если какой-то эксперимент не дал вам прироста к качеству: он все равно зачтется, если выполнен корректно.

Вот несколько идей экспериментов: * Модель RNN. Попробуйте другие нейросетевые модели — LSTM и GRU. Мы советуем обратить внимание на GRU, так как интерфейс этого класса ничем не отличается от обычной Vanilla RNN, которую мы использовали на семинаре. * Увеличение количества рекуррентных слоев модели. Это можно сделать с помощью параметра num_layers в классе nn.RNN. В такой модели выходы первой RNN передаются в качестве входов второй RNN и так далее. * Изменение архитектуры после применения RNN. В базовой модели используется агрегация со всех эмбеддингов. Возможно, вы захотите конкатенировать результат агрегации и эмбеддинг с последнего токена. * Подбор гиперпараметров и обучение до сходимости. Возможно, для получения более высокого качества просто необходимо увеличить количество эпох обучения нейросети, а также попробовать различные гиперпараметры: размер словаря, dropout_rate, hidden_dim.

Обратите внимание, что главное правило проведения экспериментов — необходимо совершать одно архитектурное изменение в одном эксперименте. Если вы совершите несколько изменений, то будет неясно, какое именно из изменений дало прирост к качеству.

8.2 Получение высокого качества (3 балла)

В конце вашей работы вы должны указать, какая из моделей дала лучший результат, и вывести качество, которое дает лучшая модель, с помощью функции evaluate. Ваша модель будет оцениваться по метрике accuracy следующим образом: * accuracy < 0.9 - 0 баллов; * $0.9 \le accuracy < 0.91 - 1$ балл; * $0.91 \le accuracy < 0.915 - 2$ балла; * $0.915 \le accuracy - 3$ балла.

8.3 Оформление отчета (2 балла)

В конце работы подробно опишите все проведенные эксперименты. * Укажите, какие из экспериментов принесли улучшение, а какие — нет. * Проанализируйте графики сходимости моделей в проведенных экспериментах. Являются ли колебания качества обученных моделей существенными в зависимости от эпохи обучения, или же сходимость стабильная? * Укажите, какая модель получилась оптимальной.

Желаем удачи!

9 Baseline model definition

```
[]: class BaselineLM(torch.nn.Module):
         def __init__(self, hidden_dim: int, vocab_size: int, num_classes: int = 4,__
      →agg_type: str = "max", dropout_rate: float = 0.1):
             super().__init__()
             self.rnn = torch.nn.Sequential(collections.OrderedDict([
                 ("embedding", torch.nn.Embedding(vocab_size, hidden_dim)),
                 ("rnn", torch.nn.RNN(input_size=hidden_dim, hidden_size=hidden_dim,_
      ⇒batch_first=True)),
             1))
             self.fc = torch.nn.Sequential(collections.OrderedDict([
                 ("fc0", torch.nn.Linear(hidden_dim, hidden_dim)),
                 ("act0", torch.nn.Tanh()),
                 ("drop", torch.nn.Dropout(p=dropout_rate)),
                 ("fc1", torch.nn.Linear(hidden_dim, num_classes))
             1))
             self.agg_type = agg_type
             if self.agg_type not in ["max", "mean"]:
                 raise ValueError("Invalid aggregation type, expected one of:
      →\"max\", \"mean\"")
         def forward(self, input):
             output, _ = self.rnn(input)
             match self.agg_type:
                 case "max":
                     output = output.max(dim=1)[0]
                 case "mean":
                     output = output.mean(dim=1)
             return self.fc(output)
```


10 Train loop

```
[]: def train_epoch(train_loader, model, optimizer, criterion, epoch, epochs_count):
         model.train()
         running_loss = 0.0
         processed = 0
         for batch in tqdm.tqdm(train_loader, desc=f"Fitting epoch {epoch + 1} / [
      →{epochs_count}", unit="batch", unit_scale=False):
             trv:
                 input, labels = batch["input_ids"].to(DEVICE), batch["label"].
      →to(DEVICE)
                 optimizer.zero_grad()
                 output = model(input)
                 loss = criterion(output, labels)
                 loss.backward()
                 optimizer.step()
                 running_loss += loss.item() * input.size(0)
                 processed += input.size(0)
             finally:
                 input, labels, output = input.cpu(), labels.cpu(), output.cpu()
                 del input, labels, output
                 torch.cuda.empty_cache()
         return (running_loss / processed)
     def eval_epoch(val_loader, model, criterion, epoch, epochs_count):
         model.eval()
         running_loss = 0.0
         processed = 0
         for batch in tqdm.tqdm(val_loader, desc=f"Evaluating epoch {epoch + 1} / [
      →{epochs_count}", unit="batch", unit_scale=False):
             try:
                 input, labels = batch["input_ids"].to(DEVICE), batch["label"].
      →to(DEVICE)
                 with torch.no_grad():
                     output = model(input)
                     loss = criterion(output, labels)
                     running_loss += loss.item() * input.size(0)
                     processed += input.size(0)
             finally:
                 input, output, labels = input.cpu(), output.cpu(), labels.cpu()
                 del batch, output, labels
                 torch.cuda.empty_cache()
         return (running_loss / processed)
```

```
[]: def train(train_loader, val_loader, model, optimizer, criterion, epochs,
      →scheduler=None, start_epoch=0):
         history = []
         start_time = time.time()
         for epoch in tqdm.tqdm(range(start_epoch, epochs), desc="Training", __
      →unit="epoch", unit_scale=False):
             try:
                 train_loss = train_epoch(train_loader, model, optimizer, criterion, u
      →epoch, epochs)
                 val_loss = eval_epoch(val_loader, model, criterion, epoch, epochs)
                 if scheduler is not None:
                     scheduler.step(val_loss)
                 history.append((train_loss, val_loss, optimizer.
      →param_groups[0]["lr"]))
             except KeyboardInterrupt as stop:
                 tqdm.tqdm.write(f"Training interrupted at epoch {epoch + 1}.__
      →Returning history")
                 return history
         end_time = time.time()
         train_time = end_time - start_time
         tqdm.tqdm.write(f"Overall training time: {train_time: 0.1f} seconds.")
         return history
[]: def plot_loss(history):
         loss, val_loss, _ = zip(*history)
         plt.figure(figsize=(15, 9))
         plt.plot(loss, label="Train loss", color="blue")
         plt.plot(val_loss, label="Validation loss", color="green")
         plt.legend(loc="best")
         plt.xlabel("Epochs")
         plt.ylabel("Loss")
         plt.show()
     def plot_learn_rate(history):
         _, _, learn_rates = zip(*history)
         plt.figure(figsize=(15, 9))
         plt.plot(learn_rates, label="Learn rate", color="red")
         plt.legend(loc="best")
         plt.xlabel("Epochs")
         plt.ylabel("Learn rate")
         plt.show()
```

11 Baseline training

```
[]: model = BaselineLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
     criterion = torch.nn.CrossEntropyLoss()
     optimizer = torch.optim.Adam(model.parameters())
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,__
      →epochs=5)
                             | 0/5 [00:00<?, ?epoch/s]
    Training:
                0%|
    Fitting epoch 1 / 5:
                                        | 0/235 [00:00<?, ?batch/s]
                          0%|
    Evaluating epoch 1 / 5:
                                           | 0/10 [00:00<?, ?batch/s]
                              0%|
    Fitting epoch 2 / 5: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 5: 0%|
    Fitting epoch 3 / 5: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 5:
                                           | 0/10 [00:00<?, ?batch/s]
                             0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 4 / 5: 0%|
    Evaluating epoch 4 / 5:
                                           | 0/10 [00:00<?, ?batch/s]
                              0%1
    Fitting epoch 5 / 5: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 5 / 5: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Overall training time: 219.7 seconds.
[]: plot_loss(history)
```



```
[]: print(f"Baseline accuracy: {evaluate(model, eval_dataloader)}")
```

Baseline accuracy: 0.896399974822998


12 Experiments

12.1 GRU

```
[ ]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

Попробуем использовать GRU.

```
("act0", torch.nn.Tanh()),
                 ("drop", torch.nn.Dropout(p=dropout_rate)),
                 ("fc1", torch.nn.Linear(hidden_dim, num_classes))
            1))
            self.agg_type = agg_type
            if self.agg_type not in ["max", "mean"]:
                raise ValueError("Invalid aggregation type, expected one of:
     →\"max\", \"mean\"")
        def forward(self, input):
            output, _ = self.rnn(input)
            match self.agg_type:
                case "max":
                    output = output.max(dim=1)[0]
                case "mean":
                    output = output.mean(dim=1)
            return self.fc(output)
[]: model = GRULM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
     criterion = torch.nn.CrossEntropyLoss()
     optimizer = torch.optim.Adam(model.parameters())
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,
     ⇒epochs=5)
    Training:
               0%|
                            | 0/5 [00:00<?, ?epoch/s]
    Fitting epoch 1 / 5: 0%|
                                      | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 1 / 5: 0%|
                                         | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 2 / 5: 0%
                                      | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 3 / 5: 0%|
                                      | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 5: 0%
                                          | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 4 / 5: 0%
                                      | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 4 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
                              | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 5 / 5: 0%|
    Evaluating epoch 5 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
    Overall training time: 226.8 seconds.
[]: plot_loss(history)
```



```
[]: print(f"GRU accuracy: {evaluate(model, eval_dataloader)}")
```

GRU accuracy: 0.9041999578475952


Уже лучше.

Попробуем использовать LSTM.

12.2 LSTM

```
[ ]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
("drop", torch.nn.Dropout(p=dropout_rate)),
                ("fc1", torch.nn.Linear(hidden_dim, num_classes))
            1))
            self.agg_type = agg_type
            if self.agg_type not in ["max", "mean"]:
                raise ValueError("Invalid aggregation type, expected one of:
     def forward(self, input):
            output, _ = self.rnn(input)
            match self.agg_type:
                case "max":
                    output = output.max(dim=1)[0]
                case "mean":
                    output = output.mean(dim=1)
            return self.fc(output)
[]: model = LSTMLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
     optimizer = torch.optim.Adam(model.parameters())
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,__
     →epochs=5)
                            | 0/5 [00:00<?, ?epoch/s]
    Training:
              0% I
                                     | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 1 / 5: 0%
    Evaluating epoch 1 / 5: 0%|
                                         | 0/10 [00:00<?, ?batch/s]
                                      | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 2 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 5: 0%
    Fitting epoch 3 / 5: 0%
                                     | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
                                  | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 4 / 5: 0%
    Evaluating epoch 4 / 5: 0%|
                                          | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 5 / 5: 0%|
                                  | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 5 / 5: 0%|
                                         | 0/10 [00:00<?, ?batch/s]
    Overall training time: 242.2 seconds.
[]: plot_loss(history)
```



```
[]: print(f"LSTM accuracy: {evaluate(model, eval_dataloader)}")
```

LSTM accuracy: 0.9045999646186829

Тоже лучше, причём метрика выше, чем при использовании GRU. Остановимся на LSTM.

Заметно, что уже после первой эпохи лосс на валидации идёт вверх, так что попробуем снизить learn rate. Проверим "Karpathy constant" (3e-4)

12.3 LR change

```
[]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
[]: model = LSTMLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
```

```
Training: 0%| | 0/5 [00:00<?, ?epoch/s]
```


Fitting epoch 1 / 5: 0% | | 0/235 [00:00<?, ?batch/s]

Evaluating epoch 1 / 5: 0%| | 0/10 [00:00<?, ?batch/s]

Fitting epoch 2 / 5: 0%1 | 0/235 [00:00<?, ?batch/s] | 0/10 [00:00<?, ?batch/s] Evaluating epoch 2 / 5: 0%| Fitting epoch 3 / 5: 0%| | 0/235 [00:00<?, ?batch/s] | 0/10 [00:00<?, ?batch/s] Evaluating epoch 3 / 5: 0%1 Fitting epoch 4 / 5: | 0/235 [00:00<?, ?batch/s] Evaluating epoch 4 / 5: 0%| | 0/10 [00:00<?, ?batch/s] | 0/235 [00:00<?, ?batch/s] Fitting epoch 5 / 5: 0%| Evaluating epoch 5 / 5: 0%1 | 0/10 [00:00<?, ?batch/s]

Overall training time: 236.4 seconds.

[]: plot_loss(history)



[]: print(f"LSTM (5 ep, 1r=3e-4) accuracy: {evaluate(model, eval_dataloader)}")

LSTM (5 ep, lr=3e-4) accuracy: 0.902999997138977

Возможно, теперь мы недообучились. Продлим обучение на ещё 5 эпох с тем же LR.


12.4 Training extension (10 epochs)

[]: history += train(train_dataloader, eval_dataloader, model, optimizer, criterion, →epochs=10, start_epoch=5)

Training: | 0/5 [00:00<?, ?epoch/s] 0%| Fitting epoch 6 / 10: 0%1 | 0/235 [00:00<?, ?batch/s] Evaluating epoch 6 / 10: 0%| | 0/10 [00:00<?, ?batch/s] Fitting epoch 7 / 10: 0%| | 0/235 [00:00<?, ?batch/s] Evaluating epoch 7 / 10: 0%| | 0/10 [00:00<?, ?batch/s] | 0/235 [00:00<?, ?batch/s] Fitting epoch 8 / 10: Evaluating epoch 8 / 10: 0%| | 0/10 [00:00<?, ?batch/s] Fitting epoch 9 / 10: | 0/235 [00:00<?, ?batch/s] 0%1 Evaluating epoch 9 / 10: 0%| | 0/10 [00:00<?, ?batch/s] | 0/235 [00:00<?, ?batch/s] Fitting epoch 10 / 10: 0%| | 0/10 [00:00<?, ?batch/s] Evaluating epoch 10 / 10: 0%1

Overall training time: 229.0 seconds.

[]: plot_loss(history)



```
[]: print(f"LSTM (10 ep, lr=3e-4) accuracy: {evaluate(model, eval_dataloader)}")
```

LSTM (10 ep, lr=3e-4) accuracy: 0.902999997138977

После пятой эпохи лосс на валидации снова пошёл вверх, так что либо после 5 эпохи уже достигнут минимум, либо необходимо снижать LR после 5 эпох дальше, что мы и попробуем сделать (используем ReduceLROnPlateau)

12.5 Training with scheduling

```
[]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
[]: model = LSTMLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
```

[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion, ⇒epochs=10, scheduler=scheduler)

```
| 0/10 [00:00<?, ?epoch/s]
Training:
           0%|
                                     | 0/235 [00:00<?, ?batch/s]
Fitting epoch 1 / 10:
                       0%1
                                        | 0/10 [00:00<?, ?batch/s]
Evaluating epoch 1 / 10:
                          0%1
Fitting epoch 2 / 10:
                                     | 0/235 [00:00<?, ?batch/s]
                       0%|
                                        | 0/10 [00:00<?, ?batch/s]
Evaluating epoch 2 / 10: 0%|
Fitting epoch 3 / 10:
                                     | 0/235 [00:00<?, ?batch/s]
                       0%1
Evaluating epoch 3 / 10: 0%|
                                        | 0/10 [00:00<?, ?batch/s]
Fitting epoch 4 / 10:
                       0%1
                                     | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 4 / 10:
                                        | 0/10 [00:00<?, ?batch/s]
                          0%1
Fitting epoch 5 / 10:
                                     | 0/235 [00:00<?, ?batch/s]
                       0%1
Evaluating epoch 5 / 10: 0%|
                                        | 0/10 [00:00<?, ?batch/s]
Fitting epoch 6 / 10: 0%
                                     | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 6 / 10: 0%|
                                        | 0/10 [00:00<?, ?batch/s]
Fitting epoch 7 / 10: 0%|
                                    | 0/235 [00:00<?, ?batch/s]
                                        | 0/10 [00:00<?, ?batch/s]
Evaluating epoch 7 / 10: 0%
Fitting epoch 8 / 10:
                                     | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 8 / 10: 0%
                                        | 0/10 [00:00<?, ?batch/s]
Fitting epoch 9 / 10:
                       0%|
                                     | 0/235 [00:00<?, ?batch/s]
```


Evaluating epoch 9 / 10: 0% | | 0/10 [00:00<?, ?batch/s]

Fitting epoch 10 / 10: 0% | | 0/235 [00:00<?, ?batch/s]


Evaluating epoch 10 / 10: 0% | | 0/10 [00:00<?, ?batch/s]

Overall training time: 464.3 seconds.

[]: plot_loss(history)



[]: plot_learn_rate(history)



LSTM (10 ep, 1r=3e-4 with scheduler) accuracy: 0.9079999923706055

Лосс на валидации не снизился, но метрика выше, так что оставим такой порядок обучения и перейдём к другим экспериментам.

12.6 Vocab size changing

Попробуем изменить размер словаря (сначала уменьшим отрезку по частоте вхождения).


```
[]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
eval_dataloader = data_utils.DataLoader(
        eval_dataset, shuffle=False, collate_fn=collate_fn_with_padding,
        batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(),_
      →pin_memory=True)
    Preprocessing:
                     0% I
                                 | 0/120000 [00:00<?, ?examples/s]
                                             | 0/102166 [00:00<?, ?tokens/s]
    Selecting frequent tokens:
                                0%|
    Vocabulary size: 19562
[]: model = LSTMLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,__
     ⇒epochs=10, scheduler=scheduler)
                             | 0/10 [00:00<?, ?epoch/s]
    Training:
               0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 1 / 10:
                           0%|
    Evaluating epoch 1 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 2 / 10: 0%
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 10: 0%
                                           | 0/10 [00:00<?, ?batch/s]
                                        | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 3 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 10: 0%
    Fitting epoch 4 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 4 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 5 / 10: 0%|
                                         | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 5 / 10: 0%|
    Fitting epoch 6 / 10: 0%|
                                         | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 6 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 7 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 7 / 10:
                              0%1
    Fitting epoch 8 / 10:
                           0%1
                                         | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 8 / 10: 0%
    Fitting epoch 9 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
                           0%1
                                          | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 9 / 10: 0%|
    Fitting epoch 10 / 10:
                            0%1
                                        | 0/235 [00:00<?, ?batch/s]
```

Evaluating epoch 10 / 10: 0%| | 0/10 [00:00<?, ?batch/s]

Overall training time: 463.8 seconds.

[]: plot_loss(history)



```
[]: print(f"LSTM (10 ep, lr=3e-4 with scheduler, counter threshold: 10) accuracy: 

→{evaluate(model, eval_dataloader)}")
```

LSTM (10 ep, lr=3e-4 with scheduler, counter threshold: 10) accuracy: 0.9041999578475952

Увеличение словаря не помогло, поэтому попробуем обратное действие и уменьшим его размер (увеличив отрезку по частоте вхождения).

```
[]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
[]: vocab, word2ind, ind2word = create_vocab(dataset, 50)
    print(f"Vocabulary size: {len(vocab)}")
    train_dataset = WordDataset(dataset["train"])
    idx = torch.randperm(len(dataset["test"]))[:5000]
    eval_dataset = WordDataset(dataset["test"].select(idx))

train_dataloader = data_utils.DataLoader(
    train_dataset, shuffle=True, collate_fn=collate_fn_with_padding,
```

```
batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(),_
      →pin_memory=True)
    eval_dataloader = data_utils.DataLoader(
         eval_dataset, shuffle=False, collate_fn=collate_fn_with_padding,
        batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(),...
      →pin_memory=True)
    Preprocessing:
                     0%1
                                 | 0/120000 [00:00<?, ?examples/s]
    Selecting frequent tokens:
                                0%1
                                             | 0/102166 [00:00<?, ?tokens/s]
    Vocabulary size: 7787
[]: model = LSTMLM(hidden_dim=256, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,
      ⇒epochs=10, scheduler=scheduler)
    Training:
               0%|
                             | 0/10 [00:00<?, ?epoch/s]
    Fitting epoch 1 / 10: 0%
                                        | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 1 / 10: 0%|
    Fitting epoch 2 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 3 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 10: 0%|
    Fitting epoch 4 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 4 / 10: 0%
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 5 / 10: 0%
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 5 / 10: 0%
                                           | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 6 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 6 / 10: 0%|
                                           | 0/10 [00:00<?, ?batch/s]
                                        | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 7 / 10: 0%
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 7 / 10: 0%|
    Fitting epoch 8 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
                                           | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 8 / 10: 0%
    Fitting epoch 9 / 10: 0%|
                                        | 0/235 [00:00<?, ?batch/s]
```


```
Evaluating epoch 9 / 10: 0% | | 0/10 [00:00<?, ?batch/s]

Fitting epoch 10 / 10: 0% | | 0/235 [00:00<?, ?batch/s]

Evaluating epoch 10 / 10: 0% | | 0/10 [00:00<?, ?batch/s]
```

Overall training time: 458.5 seconds.

[]: plot_loss(history)



```
[]: print(f"LSTM (10 ep, lr=3e-4 with scheduler, counter threshold: 50) accuracy: 

→{evaluate(model, eval_dataloader)}")
```

LSTM (10 ep, lr=3e-4 with scheduler, counter threshold: 50) accuracy: 0.9035999774932861

Аналогично предыдущему эксперименту, видно снижение метрики. Вернём отрезку к изначальному значению и проверим другие варианты.

```
[]: vocab, word2ind, ind2word = create_vocab(dataset, 10)
    print(f"Vocabulary size: {len(vocab)}")
    train_dataset = WordDataset(dataset["train"])
    idx = torch.randperm(len(dataset["test"]))[:5000]
    eval_dataset = WordDataset(dataset["test"].select(idx))

train_dataloader = data_utils.DataLoader(
    train_dataset, shuffle=True, collate_fn=collate_fn_with_padding,
```

```
batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(), □
→pin_memory=True)

eval_dataloader = data_utils.DataLoader(
    eval_dataset, shuffle=False, collate_fn=collate_fn_with_padding,
    batch_size=BATCH_SIZE, num_workers=torch.multiprocessing.cpu_count(), □
→pin_memory=True)
```

Preprocessing: 0% | 0/120000 [00:00<?, ?examples/s]

Selecting frequent tokens: 0% | 0/102166 [00:00<?, ?tokens/s]

Vocabulary size: 19562

12.7 Hidden state dimensionality manipulation

Попробуем увеличить размер скрытого состояния (до 384).

```
[]: model = model.cpu()
del model
torch.cuda.empty_cache()
```

```
[]: model = LSTMLM(hidden_dim=384, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
```


```
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion, u ⇒epochs=10, scheduler=scheduler)
```

```
| 0/10 [00:00<?, ?epoch/s]
Training:
           0% I
                                   | 0/235 [00:00<?, ?batch/s]
Fitting epoch 1 / 10: 0%
Evaluating epoch 1 / 10: 0%|
                                      | 0/10 [00:00<?, ?batch/s]
Fitting epoch 2 / 10: 0%
                                   | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 2 / 10: 0%
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 3 / 10:
                                    | 0/235 [00:00<?, ?batch/s]
                       0%1
Evaluating epoch 3 / 10: 0%
                                       | 0/10 [00:00<?, ?batch/s]
                                    | 0/235 [00:00<?, ?batch/s]
Fitting epoch 4 / 10:
                                       | 0/10 [00:00<?, ?batch/s]
Evaluating epoch 4 / 10: 0%|
Fitting epoch 5 / 10: 0%|
                                    | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 5 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 6 / 10: 0%|
                                   | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 6 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
```

| 0/235 [00:00<?, ?batch/s] Fitting epoch 7 / 10: 0% Evaluating epoch 7 / 10: 0% | 0/10 [00:00<?, ?batch/s] Fitting epoch 8 / 10: 0%| | 0/235 [00:00<?, ?batch/s] Evaluating epoch 8 / 10: 0%| | 0/10 [00:00<?, ?batch/s] Fitting epoch 9 / 10: | 0/235 [00:00<?, ?batch/s] Evaluating epoch 9 / 10: 0% | 0/10 [00:00<?, ?batch/s] Fitting epoch 10 / 10: 0% | 0/235 [00:00<?, ?batch/s] Evaluating epoch 10 / 10: 0% | 0/10 [00:00<?, ?batch/s]

Overall training time: 514.1 seconds.

[]: plot_loss(history)




[]: print(f"LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 384) accuracy: →{evaluate(model, eval_dataloader)}")

LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 384) accuracy: 0.9125999808311462

Результат улучшился (ожидаемо). Попробуем размер 512.

```
[]: model = model.cpu()
del model
```

```
torch.cuda.empty_cache()
[]: model = LSTMLM(hidden_dim=512, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
     optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion,__
     ⇒epochs=10, scheduler=scheduler)
                0% I
                             | 0/10 [00:00<?, ?epoch/s]
    Training:
                                         | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 1 / 10:
                            0%1
                                            | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 1 / 10: 0%|
    Fitting epoch 2 / 10:
                           0%|
                                         | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 2 / 10:
                                            | 0/10 [00:00<?, ?batch/s]
                              0%1
    Fitting epoch 3 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 3 / 10:
                                            | 0/10 [00:00<?, ?batch/s]
                              0%|
    Fitting epoch 4 / 10: 0%
                                         | 0/235 [00:00<?, ?batch/s]
    Evaluating epoch 4 / 10: 0%|
                                            | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 5 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
                           0%1
                                            | 0/10 [00:00<?, ?batch/s]
    Evaluating epoch 5 / 10: 0%
                                         | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 6 / 10:
    Evaluating epoch 6 / 10: 0%|
                                            | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 7 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
                           0%1
    Evaluating epoch 7 / 10: 0%|
                                            | 0/10 [00:00<?, ?batch/s]
                                         | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 8 / 10:
    Evaluating epoch 8 / 10: 0%|
                                            | 0/10 [00:00<?, ?batch/s]
    Fitting epoch 9 / 10:
                                         | 0/235 [00:00<?, ?batch/s]
                           0%1
    Evaluating epoch 9 / 10:
                              0%|
                                            | 0/10 [00:00<?, ?batch/s]
                                         | 0/235 [00:00<?, ?batch/s]
    Fitting epoch 10 / 10: 0%
    Evaluating epoch 10 / 10:
                               0%1
                                             | 0/10 [00:00<?, ?batch/s]
    Overall training time: 587.7 seconds.
[]: plot_loss(history)
```



```
[]: print(f"LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 512) accuracy: 

→{evaluate(model, eval_dataloader)}")
```

LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 512) accuracy: 0.9149999618530273

Хороший результат, но можно ли получить ещё больше? Попробуем размер 768.

```
[ ]: model = model.cpu()
  del model
  torch.cuda.empty_cache()
```

```
[]: model = LSTMLM(hidden_dim=768, vocab_size=len(vocab)).to(DEVICE)
    criterion = torch.nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=3e-4)
    scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(optimizer, patience=1)
```

[]: history = train(train_dataloader, eval_dataloader, model, optimizer, criterion, u epochs=10, scheduler=scheduler)

Training: 0% | 0/10 [00:00<?, ?epoch/s]


Fitting epoch 1 / 10: 0% | 0/235 [00:00<?, ?batch/s]

Evaluating epoch 1 / 10: 0% | 0/10 [00:00<?, ?batch/s]

Fitting epoch 2 / 10: 0% | 0/235 [00:00<?, ?batch/s]

```
Evaluating epoch 2 / 10:
                                       | 0/10 [00:00<?, ?batch/s]
                          0%1
Fitting epoch 3 / 10: 0%|
                                    | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 3 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 4 / 10: 0%
                                    | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 4 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 5 / 10:
                                    | 0/235 [00:00<?, ?batch/s]
                       0%1
Evaluating epoch 5 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 6 / 10:
                                    | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 6 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
                                    | 0/235 [00:00<?, ?batch/s]
Fitting epoch 7 / 10:
                       0%|
Evaluating epoch 7 / 10: 0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 8 / 10:
                                    | 0/235 [00:00<?, ?batch/s]
                       0%|
Evaluating epoch 8 / 10:
                          0%|
                                       | 0/10 [00:00<?, ?batch/s]
Fitting epoch 9 / 10: 0%|
                                    | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 9 / 10: 0%|
                                      | 0/10 [00:00<?, ?batch/s]
Fitting epoch 10 / 10: 0%
                                     | 0/235 [00:00<?, ?batch/s]
Evaluating epoch 10 / 10:
                           0%|
                                        | 0/10 [00:00<?, ?batch/s]
Overall training time: 1045.3 seconds.
```

[]: plot_loss(history)



```
[]: print(f"LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 768) accuracy:⊔

→{evaluate(model, eval_dataloader)}")
```

LSTM (10 ep, lr=3e-4 with scheduler, hidden dim: 768) accuracy: 0.9165999889373779

Поскольку порог в 0.915 ассигасу был пройден, нет смысла поднимать размер hidden state дальше.

13 Вывод

Было проведено 10 экспериментов:

- Изменение архитектуры (использование GRU или LSTM вместо обычной RNN).
- Смена learn rate (понижение до 3e-4, а также использование автоматического снижения LR с помощью scheduler).
- Изменение размера словаря.
- Изменение размера скрытого состояния.

Наибольшее влияние на качество возымело изменение размера hidden state.

Модель достаточно легко переобучить, примерно после 5 эпохи с LR 3e-4 функция потери на валидационных данных уже растёт, однако, динамическое понижение learn rate несколько снижает этот эффект (и увеличивает ассигасу, поэтому и было выбрано обучение на 10 эпох с scheduler).

Наилучшей моделью является модель, основанная на LSTM, с размером hidden state, равным 768, обученная 10 эпох с начальным LR 3e-4 и снижением LR в 10 раз через 2 эпохи стагнации валидационного лосса.